

Universidad del Valle de Guatemala

Facultad de Ingeniería



Excelencia que trasciende

DELVALLE
GRUPO EDUCATIVO

Laboratorio 5

Aprendizaje por Refuerzo

Integrantes:

Andy Fuentes - 22944

Diederich Solís - 22952

Diego Linares - 221256

Fecha: 20 de agosto de 2026

Repositorio del proyecto:

https://github.com/DiederichSolis/LAB5_AR

1 Task 1: Análisis teórico

1.1 Vector de características

Sea el estado normalizado $s=(d,v,e)$, donde d es densidad vehicular, v velocidad promedio y e espera acumulada. Propongo el vector cuadrático:

$$x(s) = [1, d, v, e, de, dv, ve, d^2, v^2, e^2]^T \in \mathbb{R}^{10}.$$

$x_1=1$; rango $\{1\}$. Bias: permite un nivel base distinto de cero aunque las variables sean cero.

$x_2=d$; rango $[0,1]$. Más densidad suele anticipar congestión y menor valor.

$x_3=v$; rango $[0,1]$. Resume fluidez; mayor velocidad suele asociarse con mejor desempeño.

$x_4=e$; rango $[0,1]$. Captura directamente el costo acumulado que la recompensa penaliza.

$x_5=de$; rango $[0,1]$. Distingue una cola densa y antigua de densidad transitoria.

$x_6=dv$; rango $[0,1]$. Separa tráfico denso pero móvil de tráfico denso y lento.

$x_7=ve$; rango $[0,1]$. Modela que la misma espera puede tener efecto diferente si el flujo se recupera.

$x_8=d^2$; rango $[0,1]$. Permite penalización curvada al acercarse a saturación.

$x_9=v^2$; rango $[0,1]$. Permite rendimientos no constantes de aumentos de velocidad.

$x_{10}=e^2$; rango $[0,1]$. Da mayor sensibilidad a esperas extremas y favorece evitar colas crónicas.

Aunque $\hat{V}(s;w)=w^T x(s)$ es lineal en los pesos, con estas características representa cualquier polinomio de segundo grado en las tres variables. Si solo usáramos $[1,d,v,e]$, el efecto marginal de la densidad sería constante y no podría cambiar con la espera o la velocidad. Aun con el vector propuesto no se representan exactamente umbrales abruptos, periodicidad, interacciones de grado tres, historial temporal, fase actual ni relaciones específicas por carril. En un sistema real convendría agregar fase, longitudes de cola por acceso y quizá bases radiales o tile coding si el diagnóstico de residuos muestra estructura faltante.

1.2 Parámetros y comparación tabular

Para estimar $V(s)$, cada entrada de $x(s)$ tiene un peso: $d=10$ y, por tanto, **10 parámetros**. Para control con dos acciones se puede usar codificación por bloques, $Q(s,a)=w_a^T x(s)$: hay 10 pesos por acción y **20 parámetros**.

Con 3 variables y 10 niveles por variable existen $10^3=1,000$ estados discretos. Una tabla V tendría 1,000 entradas; una tabla Q con mantener/cambiar tendría $1,000 \times 2=2,000$ **entradas**. En el Task 2 se piden 5 niveles, por lo que la tabla implementada tiene $5^3 \times 2=250$ **entradas**.

El aproximador comparte parámetros entre estados: una muestra modifica predicciones vecinas y reduce memoria y necesidad de visitar cada celda. Esa generalización introduce sesgo si el vector no expresa la relación verdadera. La tabla tiene bajo sesgo representacional sobre la discretización, pero alta varianza y demanda más cobertura; además, estados dentro de una misma celda quedan artificialmente iguales. Menos parámetros no garantiza por sí solo menos sobreajuste: características muy flexibles, poca regularización o datos no representativos pueden sobreajustar; y un modelo pequeño puede subajustar. El riesgo depende de capacidad efectiva, ruido, cobertura, política de exploración y validación fuera de muestra.

1.3 Por qué converge al punto de TD

Con $\delta_t=R_{t+1}+\gamma\hat{V}(S_{t+1};w)-\hat{V}(S_t;w)$, la actualización lineal es $w \leftarrow w+\alpha\delta_t x_t$. Es un *semi-gradiente*: se deriva la predicción actual, pero el término bootstrap $\hat{V}(S_{t+1};w)$, que también depende de w , se trata como constante. Por ello la dirección esperada no es, en general, el gradiente de $J(w)=E[(v_\pi(S)-w^T x(S))^2]$.

Bajo condiciones estándar on-policy y estacionarias, el equilibrio esperado satisface:

$$A w_{TD} = b, \quad A = E[x_t(x_t - \gamma x_{t+1})^T], \quad b = E[R_{t+1} x_t].$$

Equivale al punto fijo proyectado $Xw = \Pi_D T_\pi(Xw)$, no a la proyección directa $\Pi_D v_\pi$ que minimiza el error de predicción. Cuando el espacio de características no es cerrado bajo el operador de Bellman, ambos puntos difieren.

Al acercarse γ a 1, el horizonte efectivo $1/(1-\gamma)$ crece: errores pequeños en valores siguientes se reutilizan muchas veces. Una cota clásica on-policy contiene un factor que empeora como $1/\sqrt{1-\gamma^2}$. En tráfico, γ alto valora colas futuras, pero también propaga ruido y error de representación. Probaría (0.8, 0.9, 0.92, 0.95); usaría 0.92 como punto inicial y evitaría adoptar 0.99 sin evidencia de estabilidad. La selección final debe comparar recompensa, colas extremas, norma de pesos y desempeño fuera de muestra.

1.4 Tríada mortal y Deep RL

La tríada combina: (1) aproximación de funciones; (2) bootstrapping; y (3) aprendizaje off-policy. En este dominio, la **aproximación de funciones** es el componente inevitable y más relevante por el estado continuo; el bootstrapping es atractivo para aprender en línea. Off-policy aparece si se usa Q-Learning, replay o registros generados por otro controlador. Ningún elemento aislado basta para explicar divergencia: el riesgo aumenta cuando coinciden los tres.

Aproximación lineal. Interpretable, barata, pocos parámetros y actualización estable bajo supuestos on-policy. Generaliza desde el primer dato. Depende del diseño manual y puede subajustar interacciones complejas.

Deep RL. Representa umbrales, relaciones por carril, fases y coordinación no lineal; puede aprender características. Requiere más datos, cómputo e hiperparámetros; es menos interpretable y más sensible a objetivo móvil, correlación y off-policy.

Para una sola intersección con tres variables no está justificado saltar directamente a una red. Deep RL se justificaría si una evaluación con tráfico no visto muestra una brecha reproducible frente al modelo lineal y baselines de presión, si los residuos exhiben no linealidades sistemáticas, y si la mejora persiste en múltiples semillas, demandas y restricciones de seguridad.

2 Task 2: Implementación y experimento

2.1 Diseño experimental

El notebook define `TrafficIntersectionEnv(gym.Env)` con observación continua $[d,v,e] \in [0,1]^3$ y dos acciones. La transición combina demanda periódica con ruido; mantener conserva la fase y cambiar libera más flujo bajo congestión, con costo de transición. La recompensa penaliza espera y densidad y agrega un bono cuando el flujo supera 0.14.

Para control se usa SARSA semi-gradiente, la extensión de TD a valores de acción. A partir del vector de Task 1 se construye $\Phi(s,0)=[x(s),0]$ y $\Phi(s,1)=[0,x(s)]$, de modo que $Q(s,a;w)=w^T\Phi(s,a)$ con un solo vector $w \in \mathbb{R}^{20}$. La actualización implementada desde cero es $w \leftarrow w + \alpha \delta_t \Phi(S_t, A_t)$, con $\alpha=0.012$ y $\gamma=0.92$. Esta formulación conserva el semi-gradiente solicitado y permite elegir entre las dos acciones. La línea base usa Q-Learning, cinco bins por variable y $\alpha=0.14$. Ambos usan el mismo calendario ϵ -greedy. Se ejecutaron 600 episodios de 100 pasos y cinco semillas (7, 19, 31, 43, 59). Las curvas muestran la media entre semillas y media móvil de 30 episodios; las bandas son ± 1 desviación estándar. El ECM usa siempre los mismos 100 estados, semilla 3104, con $\hat{V}(s;w)=\max_a Q(s,a;w)$ y $V_{\text{tabular}}(s)=\max_a Q(s,a)$.

2.2 Resultados experimentales




Figura 1: Recompensa acumulada. El método lineal aprovecha generalización temprana; la tabla mejora cuando acumula visitas suficientes.

La ventaja lineal sostenida comienza alrededor del episodio 30. Se mantiene durante gran parte del entrenamiento, pero Q-Learning lo alcanza cerca del final. En los últimos 50 episodios, la recompensa media fue -10.04 para lineal y -9.60 para tabular (mayor es mejor). La diferencia respalda una conclusión matizada: la generalización mejora eficiencia de muestras al inicio, pero la tabla puede especializarse bien cuando solo tiene 250 entradas y recibe suficiente cobertura.




Figura 2: Norma L2 de los 20 pesos de acción.

La norma final media es 7.01; su pendiente media durante los últimos 50 episodios es 0.0048 por episodio. No hay crecimiento explosivo, pero la curva aún no es horizontal. Esto indica estabilidad numérica limitada en el horizonte observado, no convergencia demostrada. Posibles causas son α constante, targets con bootstrap y un vector incapaz de representar toda la dinámica. Antes de concluir divergencia conviene extender el entrenamiento, usar α decreciente y separar entrenamiento de evaluación.




Figura 3: ECM entre V lineal y V tabular sobre 100 estados fijos.

El ECM final medio es 14.12 y crece. Esto muestra que los estimadores adoptan escalas o extrapolaciones distintas. No prueba que uno sea correcto: V_{tabular} también se aprende y no es ground truth. Para medir exactitud se necesitarían retornos Monte Carlo de evaluación o una solución de referencia.

Evidencia de ejecución y configuración experimental

Comprobación	Resultado registrado
Interfaz del entorno	Gymnasium check_env: aprobado
Versión de Gymnasium	1.3.0
Semillas independientes	7, 19, 31, 43, 59
Entrenamiento	600 episodios x 100 pasos
Parámetros lineales de control	20
Entradas de Q tabular	250
Ventaja lineal sostenida	Episodio 30
Recompensa final lineal	-10.04 (últimos 50)
Recompensa final tabular	-9.60 (últimos 50)
Norma final media de w	7.01
ECM final medio	14.12

Figura 4: Evidencia reproducible de la validación del entorno, configuración y métricas registradas.

La evidencia resume la corrida ejecutada con Gymnasium real. La interfaz del entorno aprobó `check_env`; las métricas corresponden a cinco semillas independientes y se obtuvieron directamente del archivo de resultados generado por el notebook.

2.3 Investigación bibliográfica

Zhang et al. (ICML 2022), *Expression might be enough: representing pressure and demand for reinforcement*

learning based traffic signal control, estudian control de señales en redes grandes. Proponen Advanced-MP, que combina presión de vehículos en cola y demanda de vehículos en movimiento, y construyen la representación ATS. Después integran ATS en dos aproximadores profundos: Advanced-MPLight, basado en FRAP, y Advanced-CoLight, basado en atención de grafos para cooperación entre intersecciones.

Los experimentos usan CityFlow y seis conjuntos de datos reales de JiNan, HangZhou y New York; la métrica es tiempo medio de viaje y los resultados promedian tres corridas. Advanced-MP supera baselines previos en JiNan/ HangZhou y queda cerca de Efficient-CoLight en New York. Advanced-CoLight logra los mejores valores de la tabla y reporta mejoras agregadas de 13.54% frente a Efficient-MP y 6.01% frente a Efficient-CoLight. El resultado central no es “más red siempre es mejor”: la observación efectiva importa más que añadir variables indiscriminadamente, e incluso el controlador no neuronal Advanced-MP resulta competitivo y fácil de desplegar.

Nuestro modelo lineal de tres variables podría bastar como prototipo de una intersección, pero no representa topología, movimientos por carril ni cooperación entre cientos de señales. Para ese problema completo, la capacidad profunda y de grafos sí está justificada; aun así, el paper refuerza que debe compararse contra baselines de presión bien diseñados.

2.4 Dictamen técnico para la gerencia

Recomendamos iniciar el piloto con aproximación lineal enriquecida y no invertir todavía en Deep RL. En cinco semillas, el modelo lineal obtiene ventaja desde aproximadamente el episodio 30 y permanece competitivo, aunque Q-Learning logra mejor recompensa al final (-9.60 contra -10.04). La norma aún crece y el ECM se separa, por lo que la evidencia no basta para producción. El siguiente paso es validar con datos reales o un simulador calibrado, incluir fase y variables por carril, ajustar α y γ , y medir tiempo de viaje, colas máximas, seguridad y generalización. Solo si el lineal muestra una brecha estable y significativa frente a modelos no lineales en escenarios no vistos recomendamos una prueba controlada de Deep RL.

Referencias

1. CC3104. *S7 - Value Function Approximation*, diapositivas 4, 6, 7, 8 y 10.
2. CC3104. *S7 - Laboratorio 5*, pp. 1-3.
3. Zhang, L., Wu, Q., Shen, J., Lü, L., Du, B. y Wu, J. (2022). *Expression might be enough: representing pressure and demand for reinforcement learning based traffic signal control*. Proceedings of ICML, PMLR 162, 26645-26654. [Fuente primaria](#).